

Глубокое обучение и вообще

Соловей Влад

12 января 2021 г.

Посиделка 8: Transfer learning

Agenda

- Сказ о том как люди ImageNet рвали
- История про Метрику
- Transfer learning

Сказ о том, как люди ImageNet рвали

ImageNet

- около 10 миллионов размеченных изображений из интернета



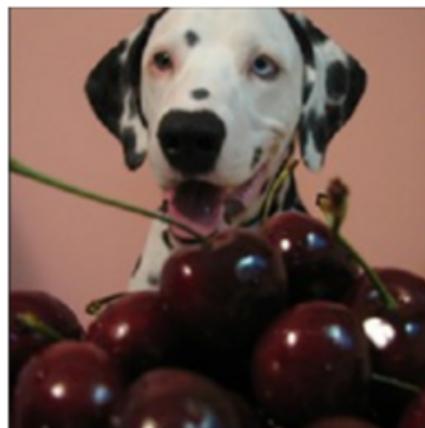
<http://www.image-net.org/>

ImageNet

- выборка очень большая и неоднородная, постоянно пополняется, соревнования на ней проводятся каждый год
- обычно изображение требуется отнести к одному из 1000 классов, можно давать несколько ответов
- если один из пяти вариантов оказался верным, то классификация считается верной
- до 2012 года лучшие алгоритмы дают ошибку в 25%
- в 2012 году на арену выходят глубокие нейронные сети

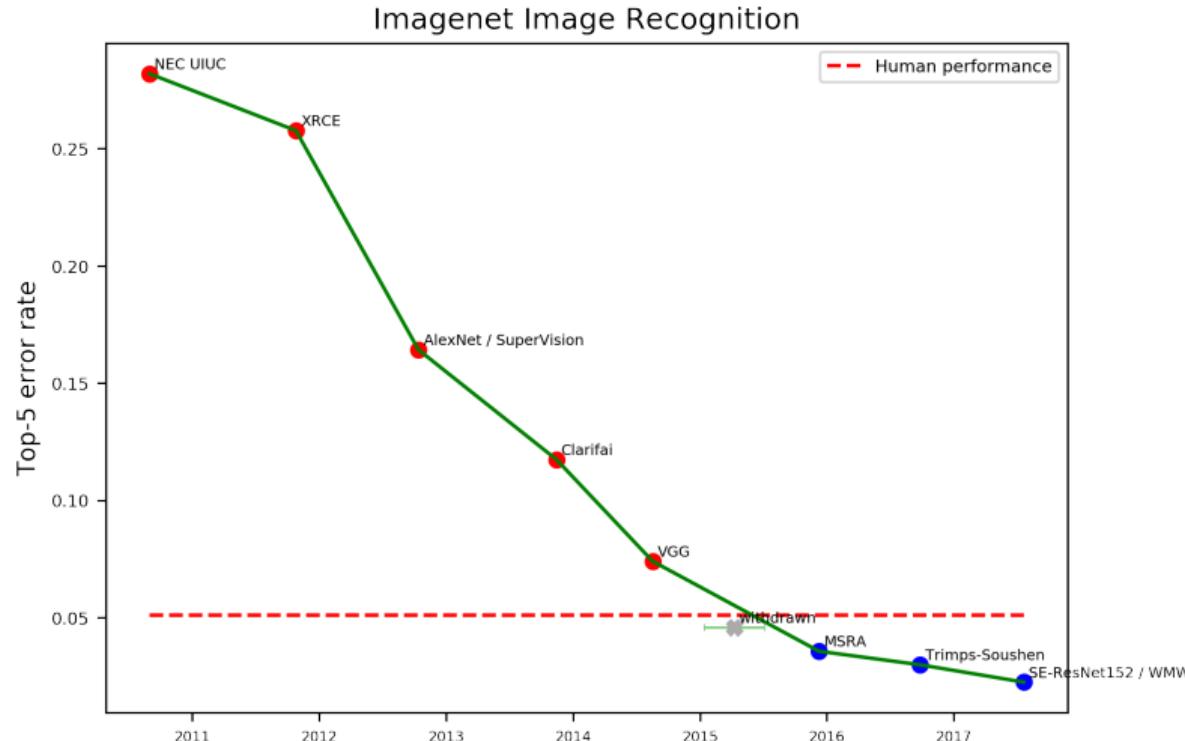
ImageNet

- бывают спорные изображения: тут вишня, если распознать как далматинец, будет неправильно

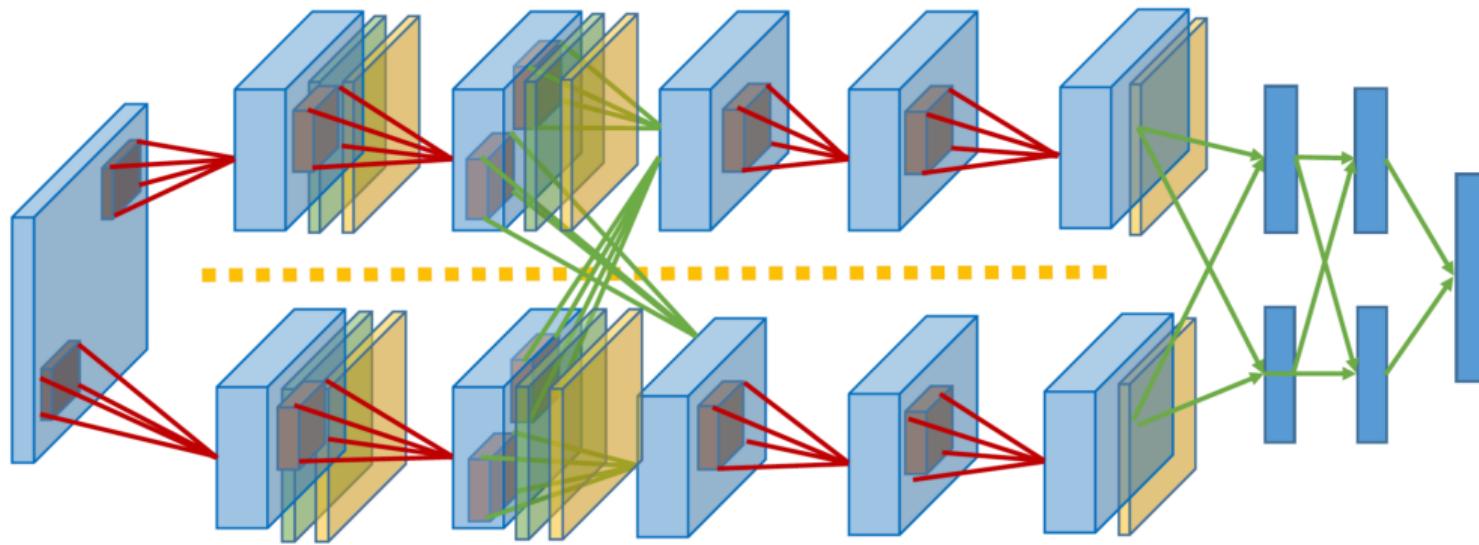
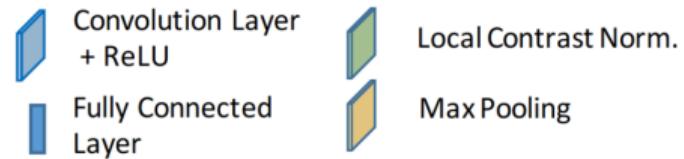


- Можно попробовать сразиться с компьютером:
<https://cs.stanford.edu/people/karpathy/ilsvrc/>

Точность сетей на ImageNet



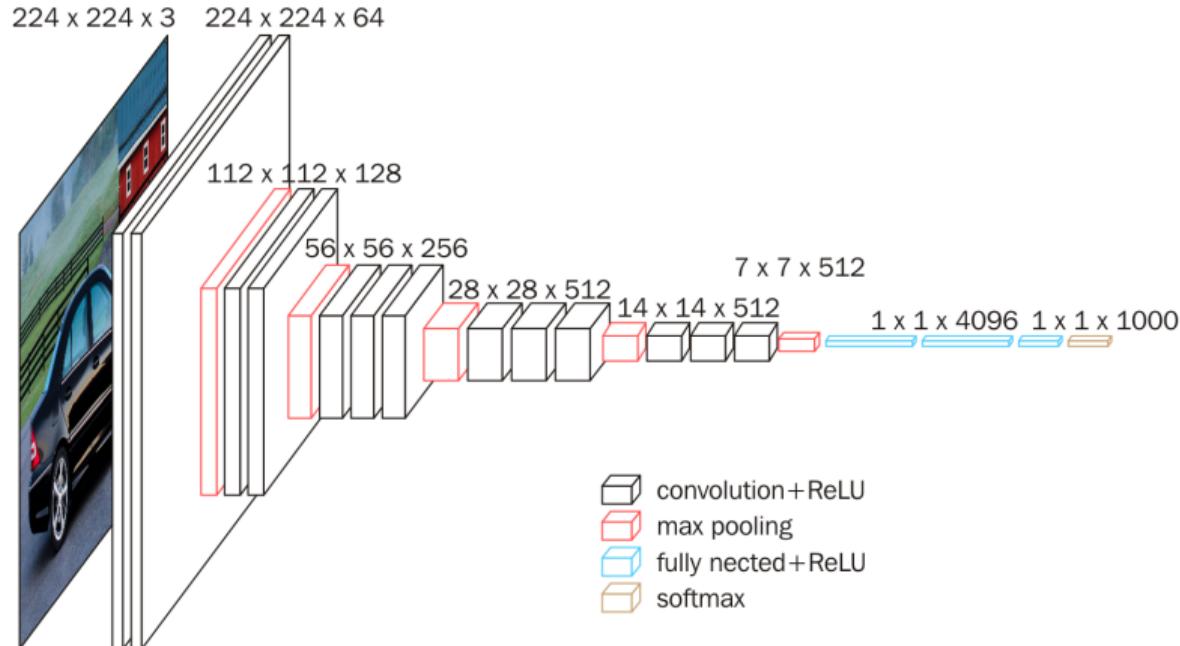
AlexNet (2012)



AlexNet (2012)

- Тот же LeNet из 1998г. но увеличен в 1000 раз и дополненный трюками (Dropout, ReLU, Data augmentation)
- Свёртки 11×11 , 5×5 , 3×3
- Уронила ошибку с 25% до 15.4%
- 60 миллионов параметров
- Училась 6 дней на 2 GPU
- Попробовали сделать ансамбль из таких сеток, ошибка упала до 11.7%

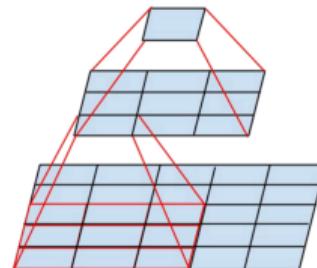
VGG (2014)



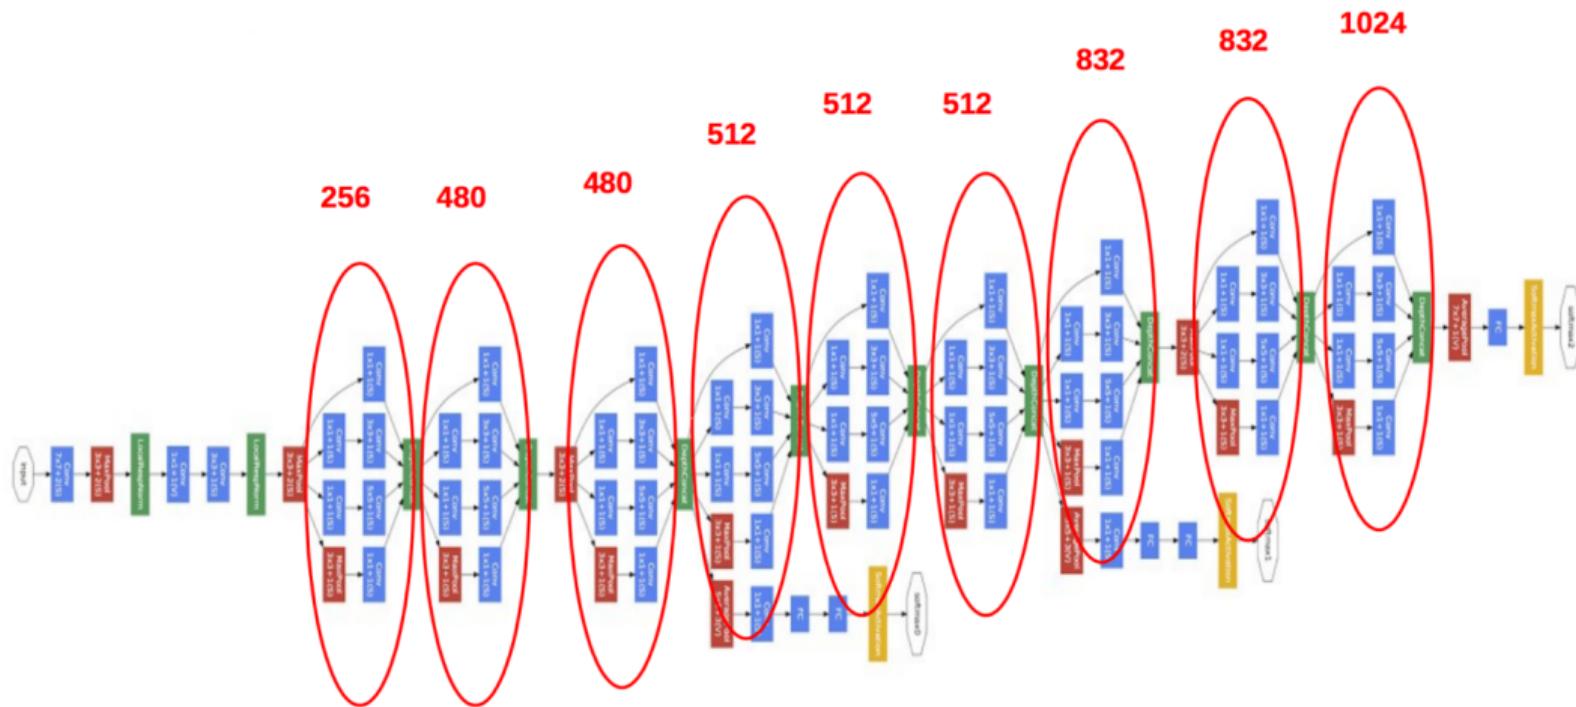
https://www.datalearner.com/paper_note/content/300035

VGG (2014)

- 138 миллионов параметров
- Училась 2 – 3 недели на 4 GPU
- Ошибка упала до 6.8%
- Свёртки только 3×3 , но намного больше фильтров для экономии параметров (две свёртки 3×3 покрывают поле 5×5 и требуют 18 параметров, а свёртка 5×5 требует 25 параметров)

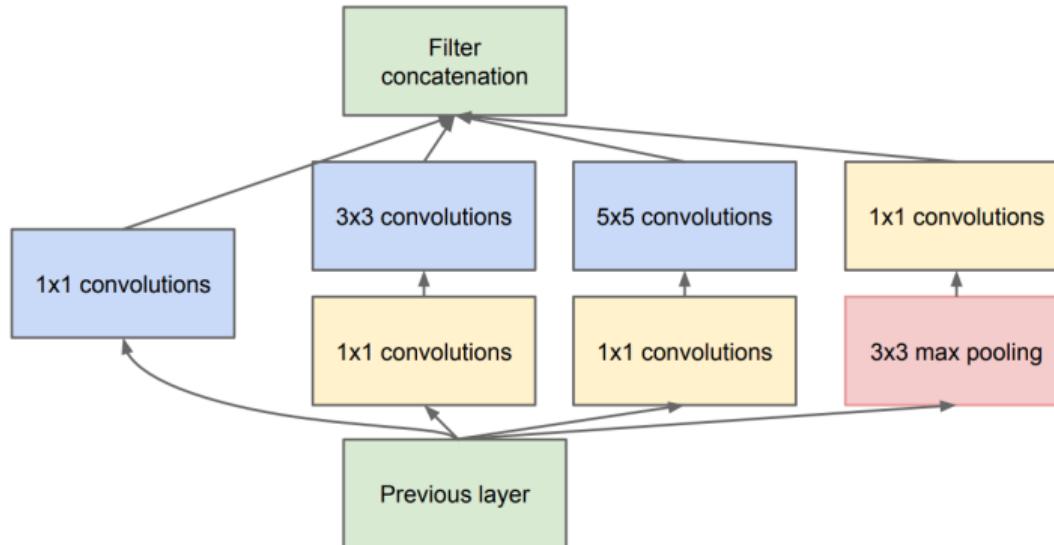


GoogleLeNet aka Inception V1 (2014)



<https://arxiv.org/abs/1409.4842>

GoogleLeNet aka Inception V1



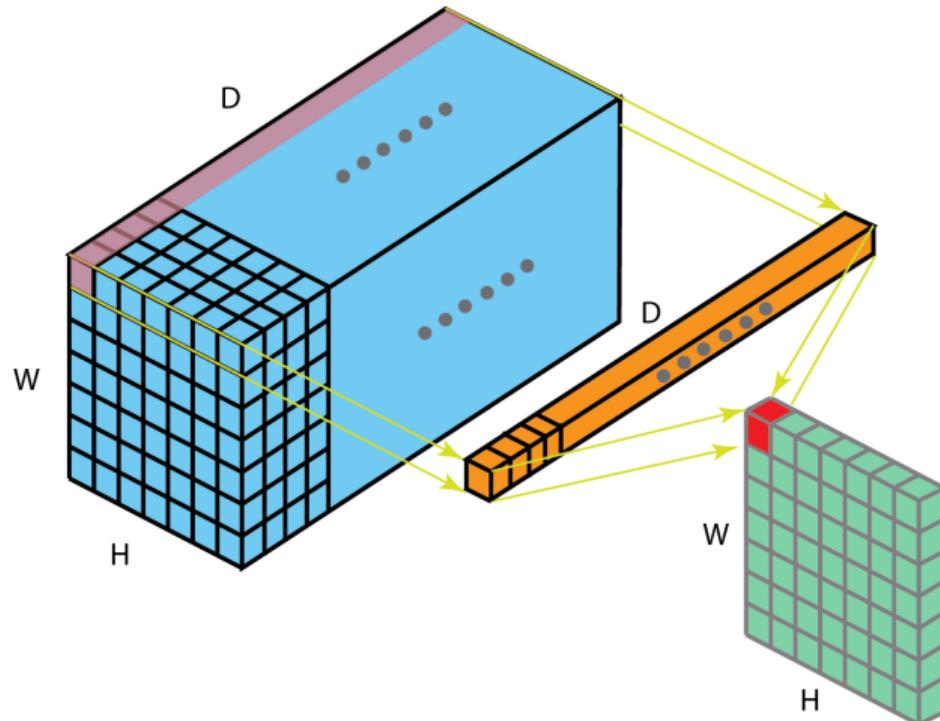
(b) Inception module with dimension reductions

GoogleLeNet aka Inception V1 (2014)

- Парни из Google решили усовершенствовать AlexNet.
- Уменьшаем свёртки, саму **сетку собираем из компонент** (всего 9 блоков).
- На каждом слое используется ни одна свёртка, а несколько разных, что помогает реагировать на сигналы разного масштаба и улучшает работу, используются **свёртки 1×1** .
- **Несколько дополнительных классификаторов на разных уровнях.** Идея в том, что такие классификаторы позволяют «протолкнуть» градиенты к ранним слоям и тем самым уменьшить эффект затухания градиента.
- Параметров в 10 раз меньше, чем в AlexNet, работает лучше, 6.7% ошибок

Свёртка 1×1

- Позволяет сократить размерность по числу каналов
- Представляет из себя полно связный слой по фильтрам
- В Inception мы делаем много разных свёрток, а потом свёрткой 1×1 выбираем из них лучшее, агрессивно понижая размерность



GoogleLeNet aka Inception V1

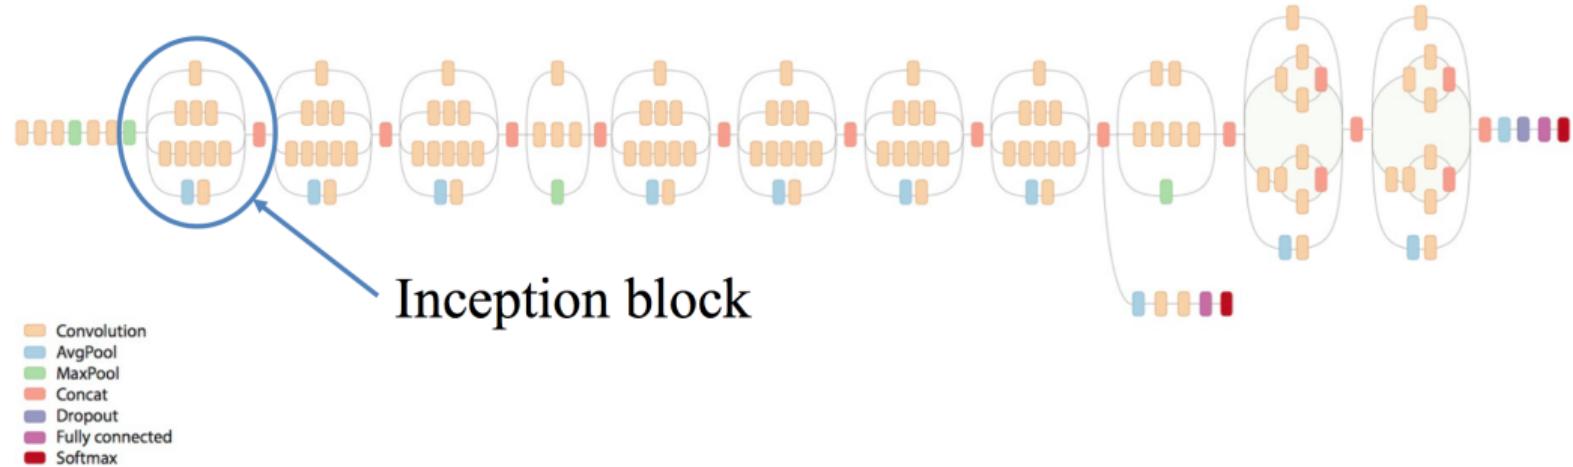
10 Acknowledgements

We would like to thank Sanjeev Arora and Aditya Bhaskara for fruitful discussions on [2]. Also we are indebted to the DistBelief [4] team for their support especially to Rajat Monga, Jon Shlens, Alex Krizhevsky, Jeff Dean, Ilya Sutskever and Andrea Frome. We would also like to thank to Tom Duerig and Ning Ye for their help on photometric distortions. Also our work would not have been possible without the support of Chuck Rosenberg and Hartwig Adam.

References

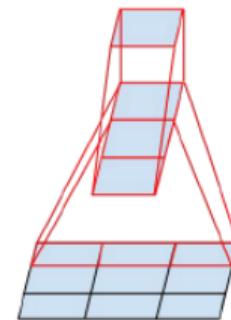
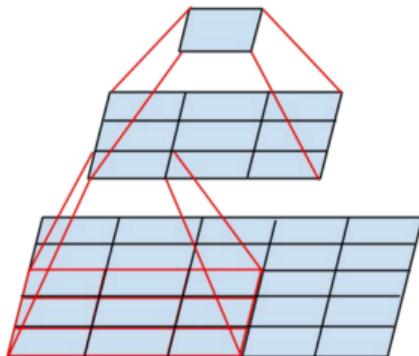
- [1] Know your meme: We need to go deeper. <http://knowyourmeme.com/memes/we-need-to-go-deeper>. Accessed: 2014-09-15.
- [2] Sanjeev Arora, Aditya Bhaskara, Rong Ge, and Tengyu Ma. Provable bounds for learning some deep representations. *CoRR*, abs/1310.6343, 2013.
- [3] Ümit V. Çatalyürek, Cevdet Aykanat, and Bora Uçar. On two-dimensional sparse matrix partitioning: Models, methods, and a recipe. *SIAM J. Sci. Comput.*, 32(2):656–683, February 2010.

Inception V3 (2015)



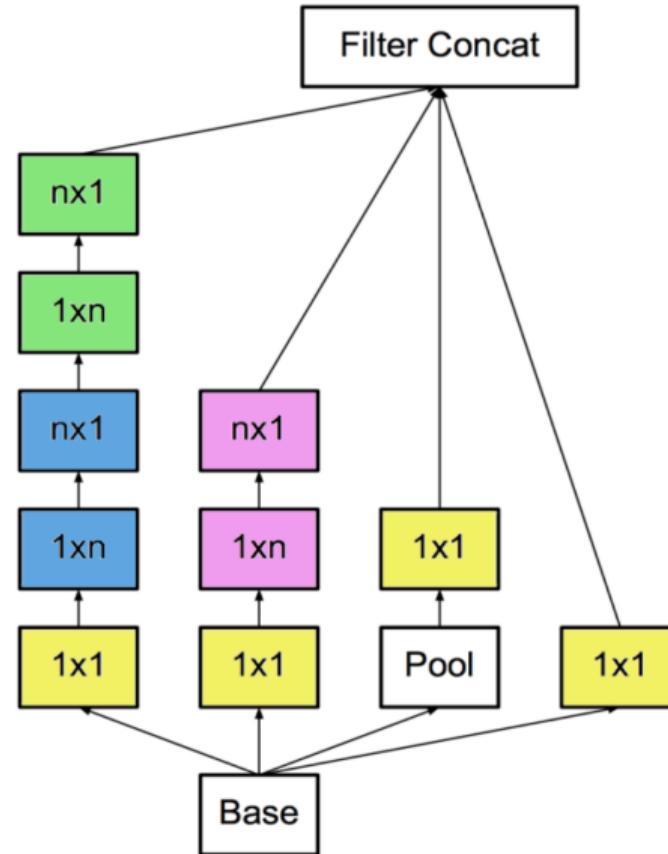
<https://arxiv.org/abs/1512.00567>

Свёртка $n \times 1$ и $1 \times n$



- В VGG заменяли большие свёртки на последовательные 3×3 для экономии
- Пойдём дальше и заменим их на последовательные 3×1 и 1×3
- Экономим ещё больше параметров, для каждой свёртки 6 вместо 9

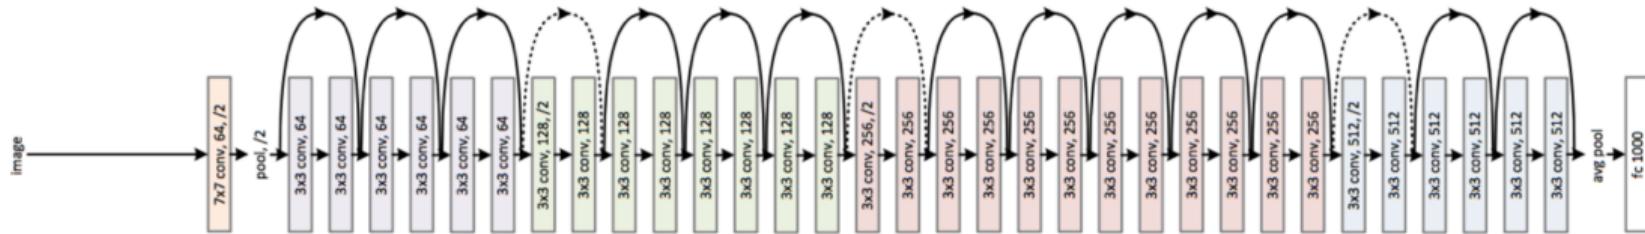
Inception V3 (2015)



Inception V3 (2015)

- Сетка собирается из 11 inception layers, добавили BatchNorm (то же самое без него Inception V2)
- В результате исследований сформулировали принципы обучения глубоких свёрточных сетей:
 1. Избегайте representation bottlenecks, нельзя резко снижать размерность слоя, это надо делать плавно: от начала к концу
 2. Свёртку нужно разбивать на более мелкие части для экономии ресурсов и увеличения размера сетки
 3. Нельзя резко увеличивать глубину, забивая на ширину, надо растить сбалансированно
- Итоговое качество 4.2% ошибок, ансамбль из 4-х моделей дал 3.8%.

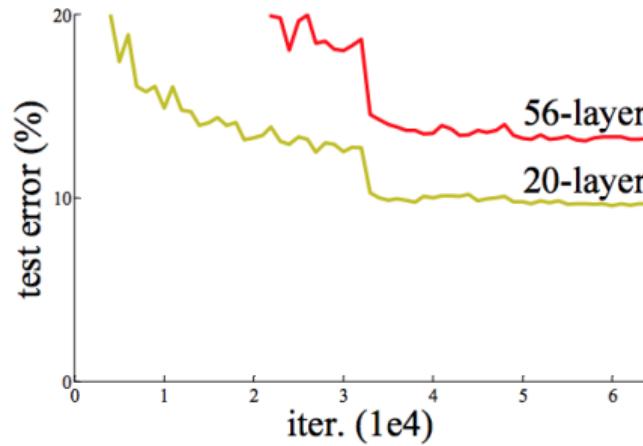
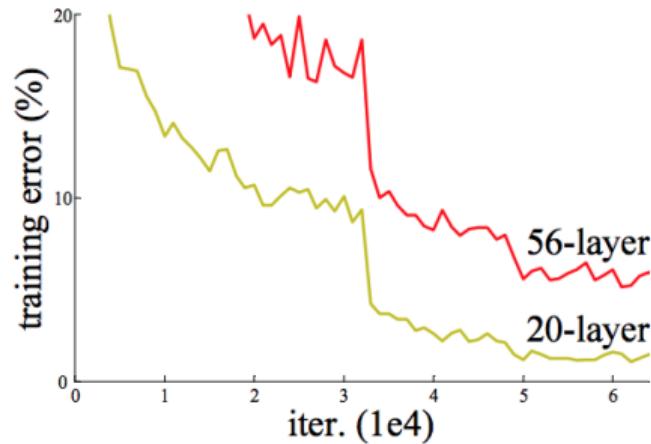
ResNet (Microsoft) (2015)



- 152 слоя, ошибка составила 3.75%, ансабль из сеток дал 3.57%

<https://arxiv.org/abs/1512.03385>

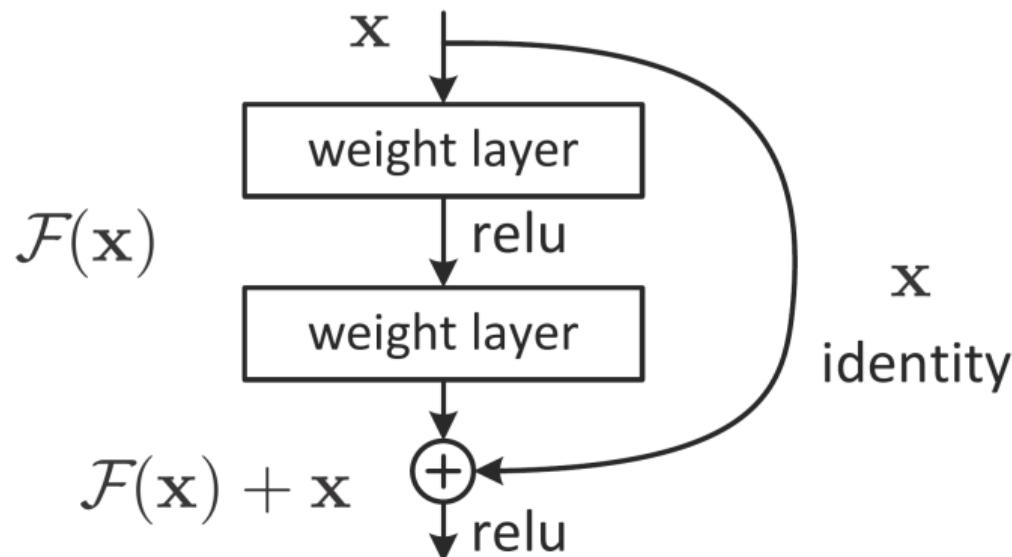
Завязочка



Завязочка

- VGG из 20 слоёв и VGG из 56 слоёв, большая сеть обучается хуже
- **Проблема:** слои инициализированы шумом, если какой-то один слой не натренирован, он убивает работу сети, через него не проходит полезный сигнал
- Чем больше слоёв, тем более ярко выражен этот эффект
- **Решение:** Будем посыпать вход на выход и давать слою возможность немного его подправить (*residual слой*)
- Идея чем-то похожа на бустинг, сеть сама решает когда заканчивать подправлять выходы (грубо говоря, сама выбирает глубину)

ResNet (Microsoft) (2015)



<https://arxiv.org/abs/1512.03385>

ResNet (Microsoft) (2015)

- **Идея:** более глубокие уровни должны улавливать разницу между новым и тем, что было раньше
- Ключевым элементом архитектуры является связь, которая пропускает несколько слоёв, передавая результат предыдущего слоя
- Такое изменение позволило полностью отказаться от таких техник регуляризации, как DropOut
- Градиенты не взрываются, свойства ResNet активно пытаются сейчас изучать

Что было дальше?

- В 2016 году Google попробовал Inception-Resnet и поставил ансамблем новый рекорд, 3.08%

<https://arxiv.org/abs/1602.07261>

- После Google задумались о переносе своих огромных архитектур в мобильные телефоны и стали работать над их компактностью

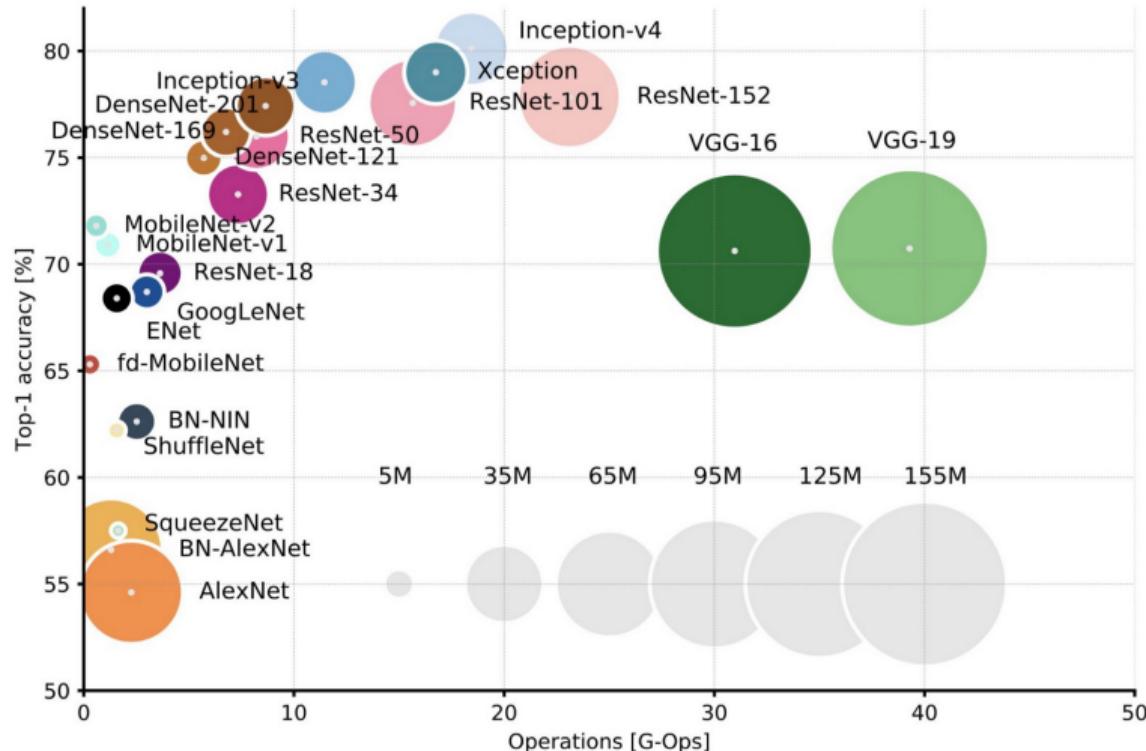
<https://ai.googleblog.com/2018/04/mobilenetv2-next-generation-of-on.html>

- В целом область развивается очень динамично и всплывает куча идей, на хабре иногда есть рубрика "Читаем статьи за вас", там можно посмотреть сколько идей возникло только за осень 2017

<https://habr.com/ru/company/ods/blog/343822/>

Слайд из первой презентации :)

2. Сложность сетей растёт



<https://towardsdatascience.com/neural-network-architectures-156e5bad51ba>

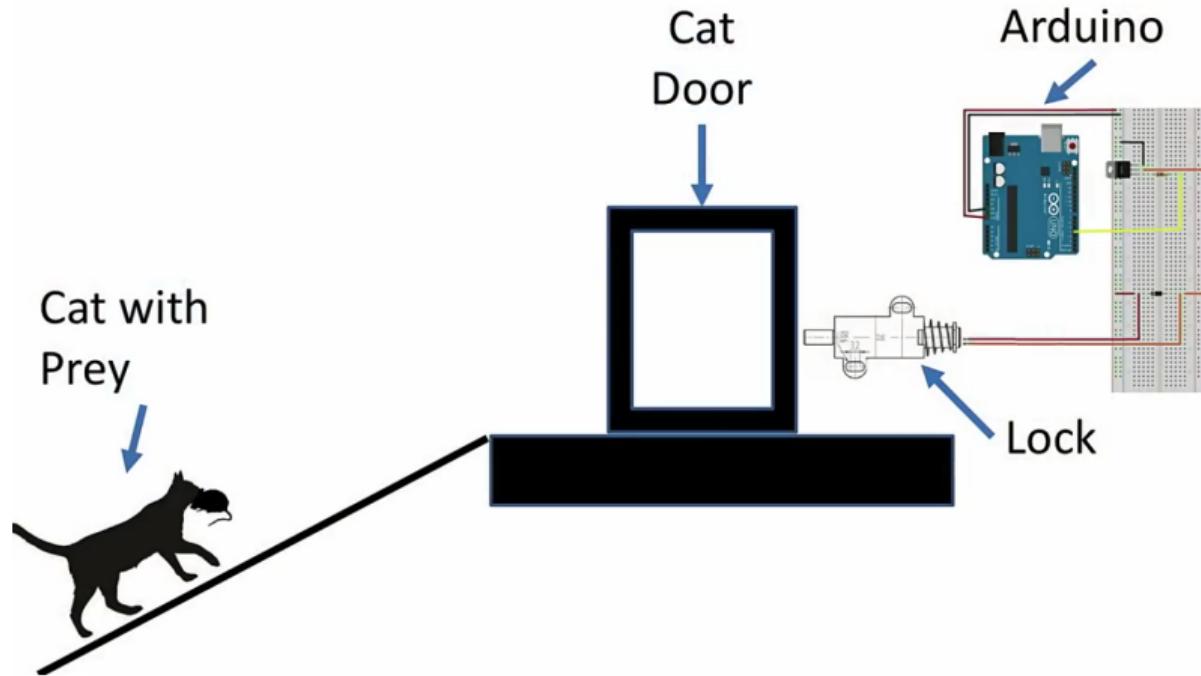
История про Метрику

Метрика это кот



<https://www.youtube.com/watch?v=1A-Nf3QIJjM>





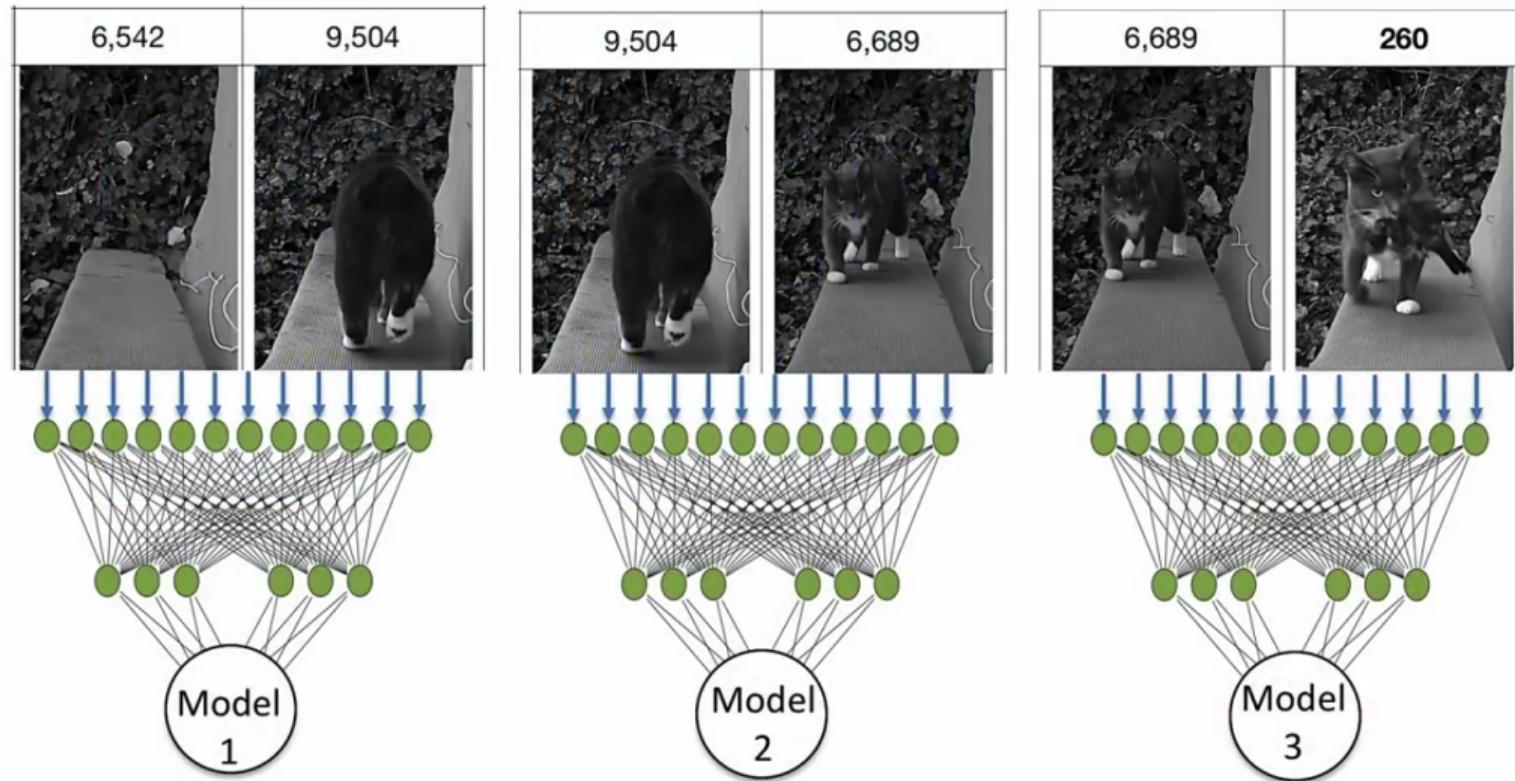




VS.



Image Type	No Cat	Cat not on approach	Cat on approach	Cat with prey
Count of Images	6,542	9,504	6,689	260
Example				



CRITTER DETECTED!

Step 1:
Lock the door!



Step 2:
Text me pics

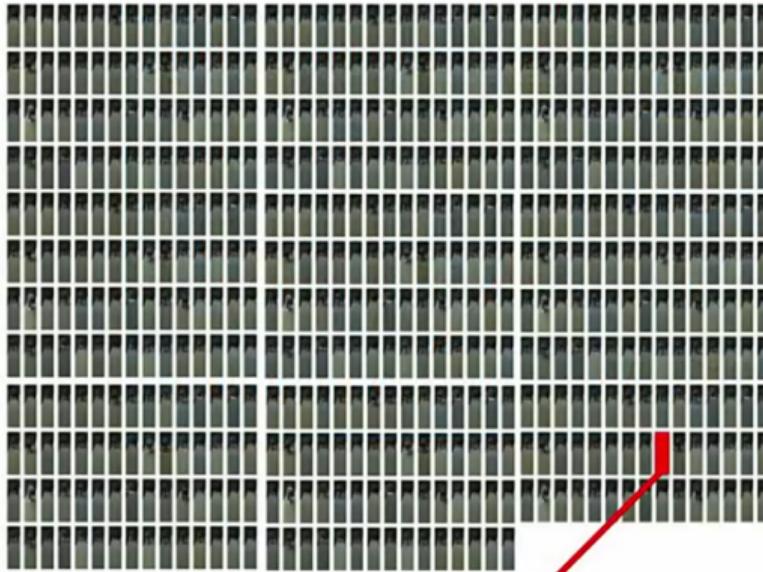


Step 3:
Donate blood
money



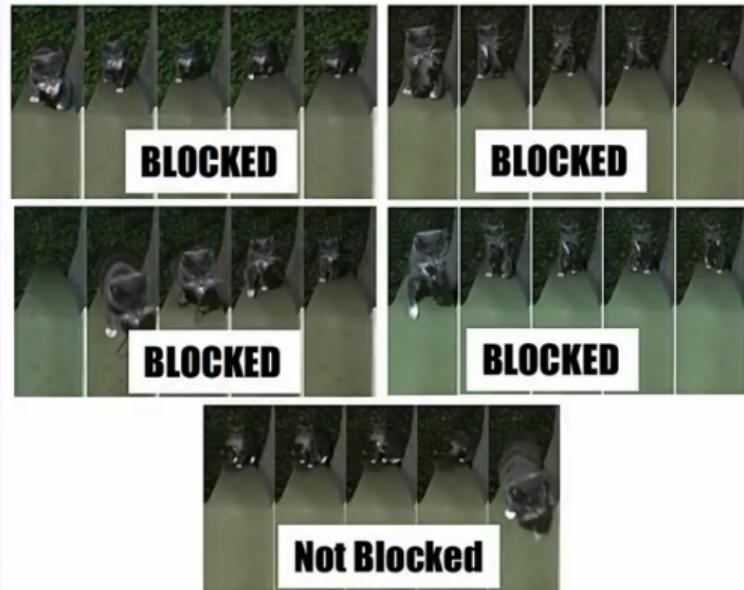
Audubon

Innocent Entries



1 Unfair Lockout

Entries with Prey



4/5 Critters Blocked

Как он это сделал?

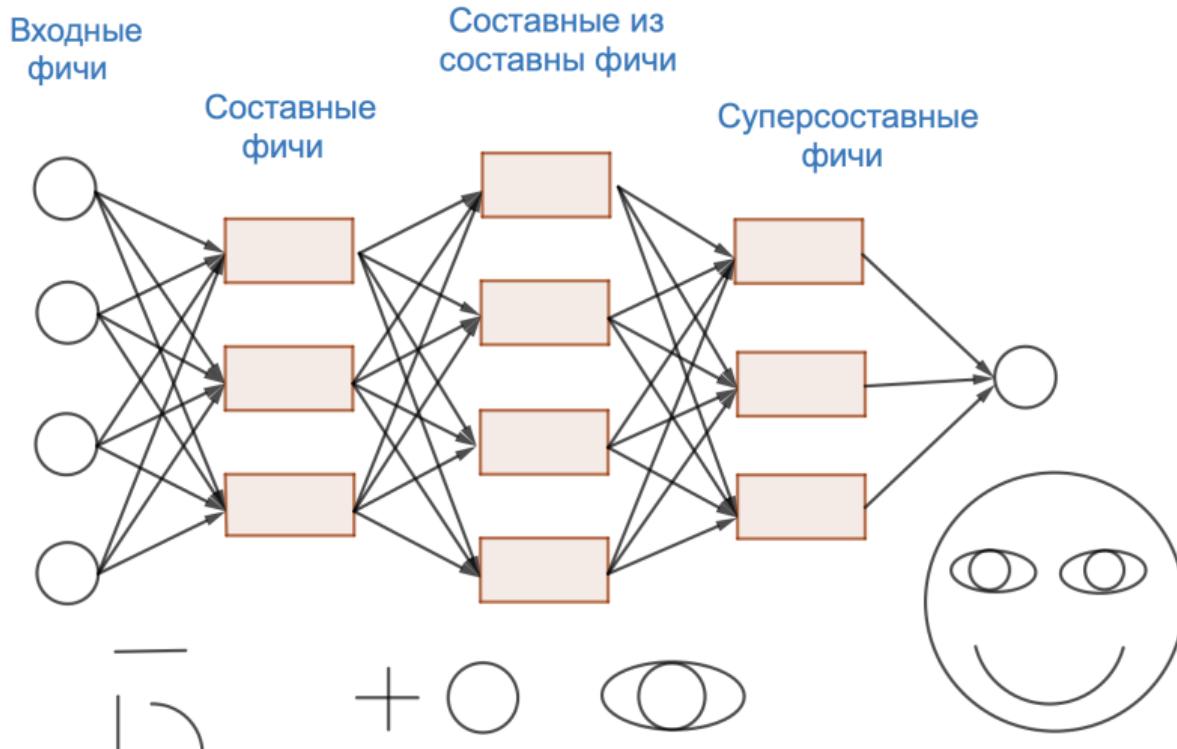
- В выборке было всего лишь 260 фотографий кота с добычей, неужели этого хватило для обучения сетки?
- На самом деле сетку с нуля никто не учил, делался transfer learning

Transfer learning

Как он это сделал?

- На практике свёрточные сети с нуля обучаются только огромные компании
- Это происходит из-за ограниченности ресурсов
- Уже обученные архитектуры пытаются адаптировать под новые задачи, это называется **transfer learning**

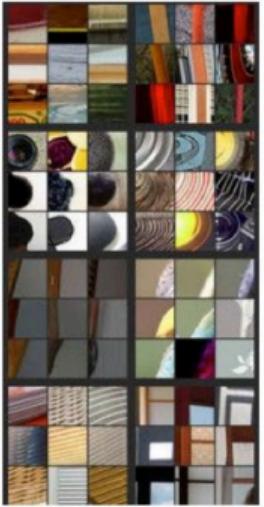
Что выучивают нейросети



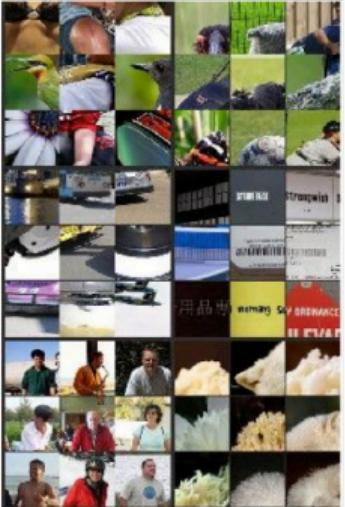
Что выучивают нейросети



Layer 1



Layer 2



Layer 3



Layer 4

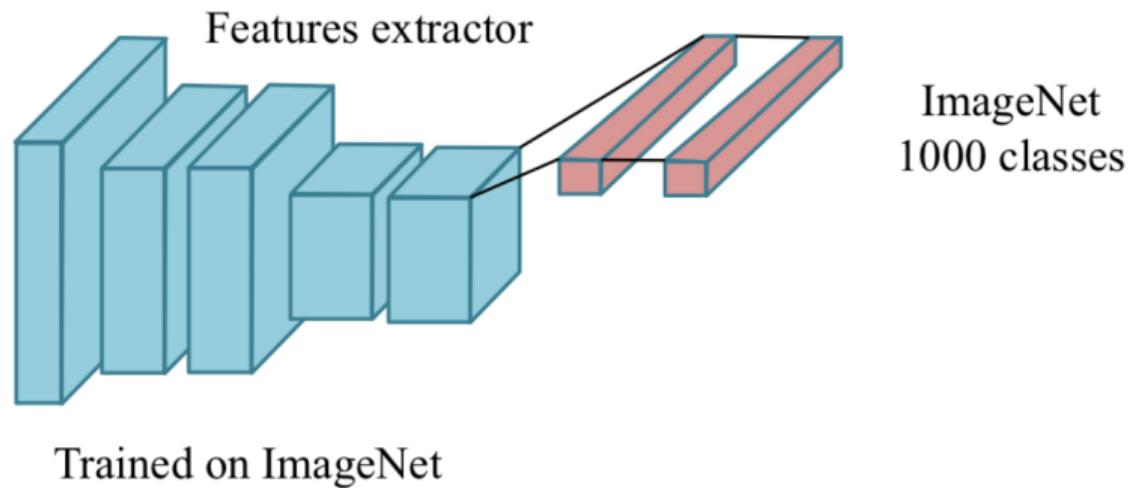


Layer 5

<https://arxiv.org/pdf/1311.2901.pdf>

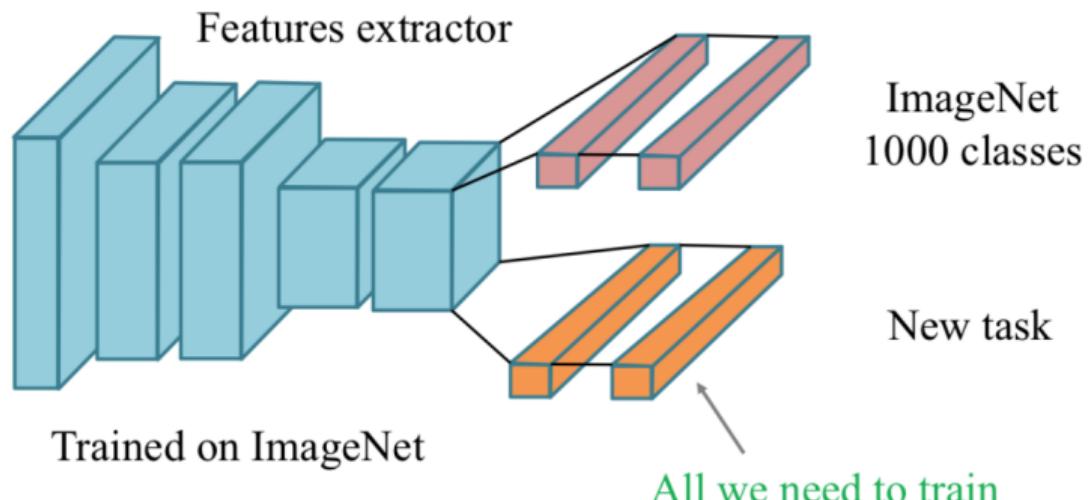
Transfer learning

- Глубокие сети извлекают из изображений сложные фичи, но для их обучения нужно много данных...



Transfer learning

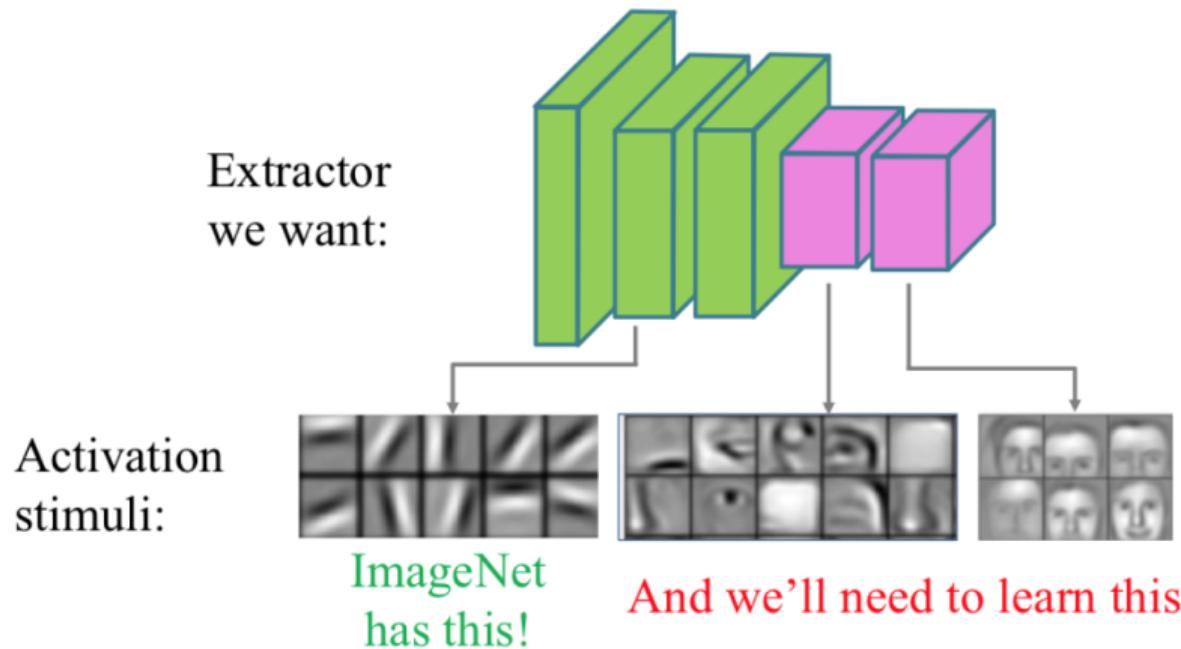
- Глубокие сети извлекают из изображений сложные фичи, но для их обучения нужно много данных...
- Давайте повторно использовать уже предобученную сеть!



Transfer learning

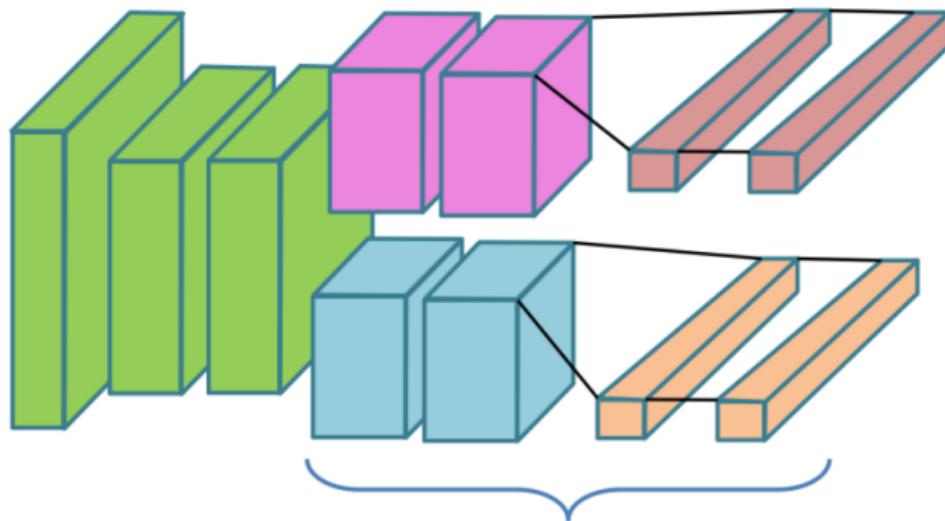
- Нужно меньше данных для обучения, так как нас интересуют лишь последние слои
- Это работает если наша задача похожа на ту, для которой обучалась используемая сетка
- Например, если мы хотим распознавать эмоции, в датасете для нашей сетки должны были быть человеческие лица

Transfer learning



Transfer learning

ImageNet features extractor



ImageNet
1000 classes

New task

All we need to train

Крокодил learning

cifar X

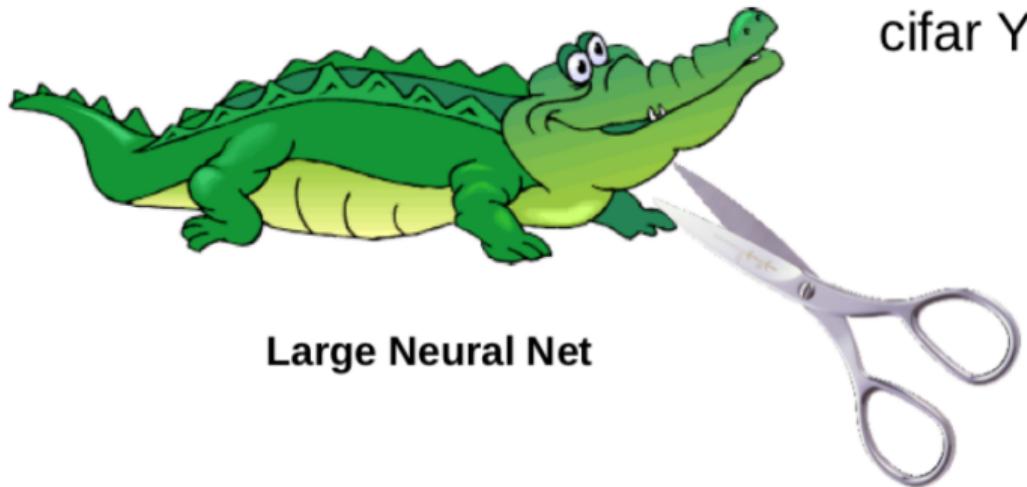


cifar Y

Large Neural Net

Крокодил learning

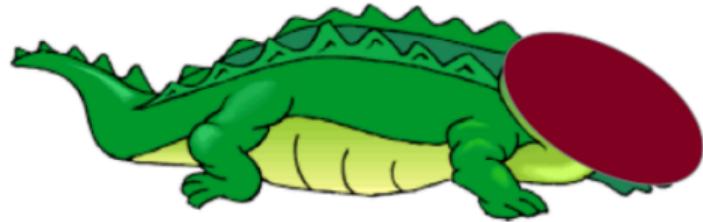
cifar X



Крокодил learning

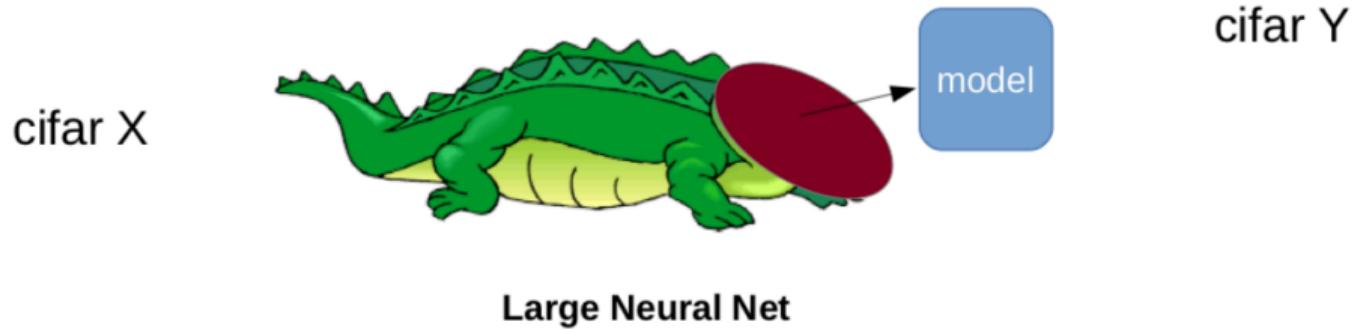
cifar X

cifar Y

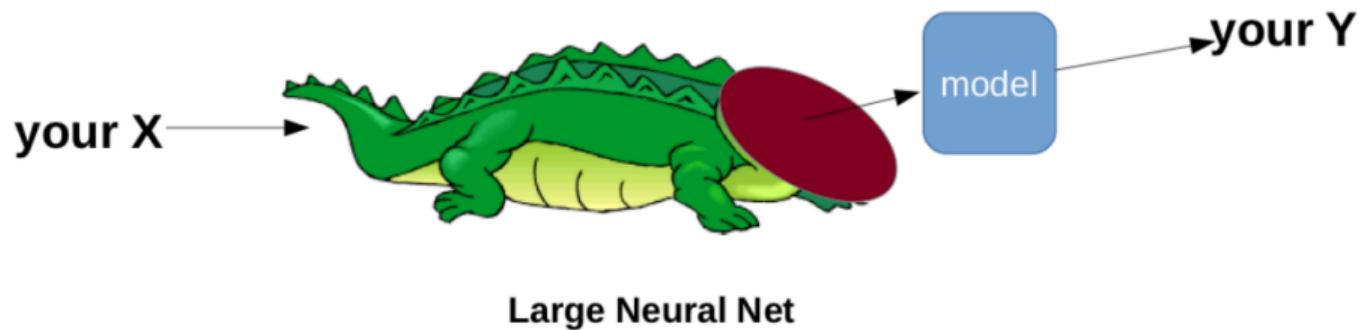


Large Neural Net

Крокодил learning



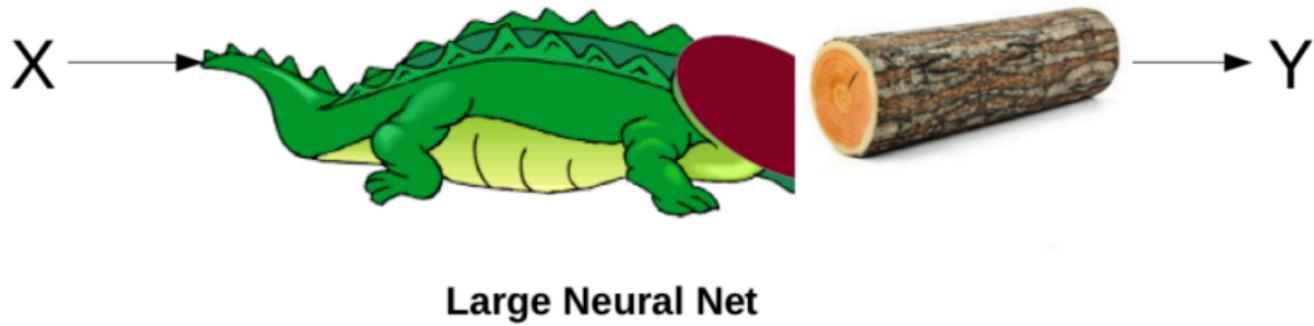
Крокодил learning



Крокодил learning

- Отрезали у крокодила голову
- Используем тело крокодила как экстрактор фичей
- Вместо головы крокодила можно прикрепить что угодно
- Даже случайный лес и бустинг
- В экстракторе фичей веса модели обычно не дообучают, дообучение касается только новой головы крокодила

Крокодил learning



Зоопарки моделей

- Перед тем как решать задачу с нуля, убедитесь, что готового решения
ещё нет
- Зоопарк моделей внутри Tensorflow
- Другой большой зоопарк: <https://modelzoo.co/>

Собираем своего крокодила!